




Detecção de Fraude com Machine Learning

Projeto de análise e modelagem preditiva — uma abordagem prática para identificar transações fraudulentas com precisão e responsabilidade.

O Problema que Queremos Resolver

O impacto das fraudes financeiras

Fraudes em transações financeiras geram perdas expressivas para empresas todos os anos. Mas o desafio vai além do prejuízo direto: quando o sistema é excessivamente restritivo, transações legítimas são bloqueadas, prejudicando a experiência do cliente.

O equilíbrio necessário

O verdadeiro desafio está em encontrar o ponto certo: **detectar o máximo de fraudes possível** sem gerar um número excessivo de falsos positivos — bloqueios desnecessários que frustram usuários legítimos.



Objetivo do Projeto

1

Alta taxa de detecção

Desenvolver um modelo com alto recall — isto é, capaz de identificar a maior parte das fraudes reais presentes nos dados.

2

Baixo número de falsos positivos

Garantir que transações legítimas não sejam bloqueadas desnecessariamente, preservando a experiência do usuário.

3

Modelo generalizável


Construir uma solução que aprenda padrões reais de fraude, e não artefatos dos dados de treinamento.

FONTE DE DADOS

O Dataset Utilizado

Foi utilizado um **dataset sintético de fraude financeira disponível no Kaggle**, amplamente usado em projetos educacionais e de pesquisa na área.

⚠ Por ser um conjunto de dados sintético, os resultados podem não refletir fielmente cenários do mundo real. Essa limitação é considerada na interpretação dos resultados.



Variáveis Principais

amount

Valor monetário da transação realizada.

hour

Horário em que a transação ocorreu.

transaction_type

Tipo de operação: compra, transferência, saque, etc.

merchant_category

Categoria do estabelecimento comercial envolvido.

country

País onde a transação foi realizada.

is_fraud

Variável alvo: indica se a transação é fraude (1) ou não (0).

Análise Exploratória dos Dados



O que os dados revelaram

A exploração dos dados foi essencial antes de qualquer modelagem. Três pontos chamaram atenção imediatamente:

- **Desbalanceamento:** a grande maioria das transações é legítima. Sem tratamento, o modelo tenderia a ignorar as fraudes.
- **Alta correlação:** algumas variáveis mostraram correlação suspeita com o target, levantando dúvidas sobre sua origem.
- **Possível vazamento de dados:** variáveis que "já sabem" o resultado comprometem a generalização do modelo.

Decisões de Pré-processamento

→ Remoção de variáveis problemáticas

As variáveis `device_risk_score`, `ip_risk_score` e `country_ng` foram removidas por apresentarem correlação muito alta com o target — o que configura risco real de vazamento de informação.

→ Codificação de variáveis categóricas


As variáveis do tipo texto foram transformadas em representações numéricas para que os algoritmos pudessem processá-las corretamente.

→ Balanceamento com `class_weight`


O parâmetro `class_weight='balanced'` foi aplicado para compensar o desbalanceamento entre fraudes e transações legítimas, sem necessidade de reamostrar os dados.

Machine Learning Data Processing Pipeline Feature Engineering Workflow

Feature Engineering



Feature Transformation



Modelos Utilizados e Otimização

Random Forest

Modelo baseado em ensemble de árvores de decisão. Foi escolhido como modelo final por apresentar melhor desempenho na detecção de fraudes, com **recall de 98%** e **f1-score de 99%** na classe de fraude.

XGBoost

Algoritmo de gradient boosting bastante utilizado. Foi usado como comparação e também apresentou bom desempenho, com **recall de 96%** e **f1-score de 97%** na classe de fraude.

Como os hiperparâmetros foram ajustados

Foi utilizado o **RandomizedSearchCV** para explorar diferentes combinações de hiperparâmetros de forma eficiente. A métrica de referência foi o **recall**, complementado pelo **f1-score** — garantindo que o modelo detecte mais fraudes sem perder precisão demais.

 O foco no recall reflete diretamente o objetivo do projeto: minimizar fraudes não detectadas.

Resultados e Comparação dos Modelos

Random Forest – Modelo Final

Apresentou alto desempenho geral, com bom equilíbrio entre precisão e recall. Destacou-se especialmente na **detecção de fraudes**, com maior recall entre os modelos testados — o que o tornou a escolha final do projeto.

XGBoost – Modelo de Comparação

Também apresentou resultados robustos, com métricas gerais competitivas. No entanto, mostrou uma **leve queda no recall** em relação ao Random Forest, ou seja, deixou escapar mais fraudes na detecção.

Ambos os modelos apresentaram desempenho elevado. O critério de decisão foi o **recall na classe de fraude** — e nesse ponto o Random Forest foi mais consistente.

Aprendizados, Impacto e Próximos Passos

Principais aprendizados

- Métricas muito altas podem ser sinal de problema nos dados, não de sucesso real.
- Variáveis correlacionadas ao target podem introduzir viés e comprometer a generalização.
- Remover essas variáveis melhora a confiabilidade do modelo em cenários reais.

Impacto prático

- Maior detecção de fraudes significa menos perdas financeiras para a empresa.
- Menos falsos positivos significa melhor experiência para o cliente.

Próximos passos

01

Testar com dados reais

Validar o modelo em transações reais para verificar sua capacidade de generalização fora do ambiente sintético.

02

Validação mais robusta

Aplicar técnicas como validação temporal ou cross-validation estratificado para resultados mais confiáveis.

03

Avaliação em produção

Monitorar o modelo em ambiente real, com atenção a deriva de dados e atualização periódica.

Este projeto reforça que a análise cuidadosa dos dados vale mais do que qualquer técnica avançada. Um modelo robusto começa com dados bem compreendidos.