




# Detecção de Fraude com Machine Learning

Um projeto de ponta a ponta: da limpeza dos dados à seleção do modelo final com desempenho excepcional na identificação de fraudes.

# Visão Geral do Projeto



O pipeline foi estruturado para garantir modelos generalizáveis e confiáveis, desde o pré-processamento até a escolha do algoritmo com melhor desempenho real.

# Pré-processamento e Engenharia de Features

## Variáveis Categóricas


Aplicação de técnicas de encoding para transformar variáveis categóricas em representações numéricas adequadas.

## Remoção de Viés

Exclusão de `device_risk_score`, `ip_risk_score` e `country_ng` — colunas que introduziam viés e comprometiam a generalização.

## Alteração Tipo de Dados

Alteração do tipo de dados das colunas para garantir consistência e melhor desempenho do modelo.



# Otimização com RandomizedSearchCV



## Por que RandomizedSearchCV?

Em vez de testar exhaustivamente todas as combinações de hiperparâmetros (GridSearch), o **RandomizedSearchCV** amostra aleatoriamente o espaço de busca, reduzindo drasticamente o custo computacional sem sacrificar a qualidade da otimização.

- Busca eficiente em espaços de alta dimensionalidade
- Validação cruzada integrada para evitar overfitting
- Aplicado a ambos os modelos: Random Forest e XGBoost

MODELOS AVALIADOS

# Random Forest vs. XGBoost



## Random Forest


Ensemble de árvores de decisão com votação majoritária.  
Robusto a overfitting e altamente interpretável em cenários de detecção de anomalias.



## XGBoost

Gradient boosting otimizado, com excelente desempenho em dados tabulares. Treinamento sequencial que corrige erros iterativamente.

# XGBoost: Desempenho Sólido




## Interpretação dos Resultados

O XGBoost atingiu **100% de acurácia** na base de teste. Para transações normais, classificação perfeita. Para fraudes, **precisão de 98%** e **recall de 96%** — excelente equilíbrio entre falsos positivos e falsos negativos.

**i** F1-Score de 97% para a classe de fraude demonstra alta confiabilidade operacional.

# Random Forest: O Modelo Campeão



## Desempenho Excepcional

O Random Forest atingiu **100% de acurácia** com classificação perfeita para transações normais. Na detecção de fraudes, **zero falsos positivos** e apenas **2 fraudes não detectadas** em toda a base de teste.

✅ F1-Score de 99% para fraudes — o melhor resultado entre os modelos avaliados.

# Comparativo Final dos Modelos

| Métrica (Classe 1 — Fraude) | XGBoost | Random Forest | Diferença | Vencedor      |
|-----------------------------|---------|---------------|-----------|---------------|
| Precisão                    | 98%     | 100%          | +2 p.p.   | Random Forest |
| Recall                      | 96%     | 98%           | +2 p.p.   | Random Forest |
| F1-Score                    | 97%     | 99%           | +2 p.p.   | Random Forest |
| Falsos Positivos            | Alguns  | Zero          | —         | Random Forest |

Em todas as dimensões críticas para detecção de fraude, o Random Forest superou o XGBoost, consolidando-se como a escolha definitiva.





# Modelo Final: Random Forest

## Zero Falsos Positivos

Nenhuma transação legítima classificada incorretamente como fraude.

## 98% de Recall

Apenas 2 fraudes não detectadas em todo o conjunto de teste.

## F1-Score 99%

Equilíbrio quase perfeito entre precisão e sensibilidade na classe de fraude.

# Conclusões e Próximos Passos

## O que foi alcançado

- Pipeline robusto com remoção de features enviesadas
- Otimização eficiente via RandomizedSearchCV
- Random Forest com desempenho de produção: 99% F1 para fraudes
- Modelo confiável e generalizável para novos dados

## Direções Futuras

- Monitoramento contínuo com detecção de drift de dados
- Explorar técnicas de explicabilidade (SHAP, LIME)
- Avaliar performance em dados de produção em tempo real
- Investigar aprendizado incremental para adaptação ao padrão de fraude

✅ O modelo está pronto para implantação — com alta confiabilidade, baixo índice de erros e generalização comprovada.