


Detecção de Fraude com Machine Learning

Um projeto de ML voltado à redução de perdas financeiras e eliminação de bloqueios indevidos — equilibrando precisão na detecção sem comprometer a experiência do cliente.

PYTHON · SCIKIT-LEARN · XGBOOST · RANDOM FOREST





O Problema

Impacto das Fraudes

Fraudes financeiras geram prejuízo direto para as empresas e degradam a confiança do consumidor. O desafio vai além de simplesmente bloquear transações suspeitas.

O Equilíbrio Crítico

Detectar o máximo de fraudes possível **sem afetar usuários legítimos**. Cada falso positivo representa um cliente frustrado e uma venda perdida.

Dataset e Variáveis

Dataset sintético de fraude disponível no Kaggle, com variáveis que descrevem o contexto completo de cada transação.

amount

Valor monetário da transação

hour

Horário em que ocorreu a transação

transaction_type

Tipo de operação realizada

merchant_category

Categoria do estabelecimento

country


País de origem da transação

is_fraud


Variável alvo: 0 = legítima · 1 = fraude

Análise Exploratória dos Dados


1) Forte desbalanceamento de classes entre fraude e não fraude



2) Algumas variáveis apresentavam correlação muito alta com a variável alvo



3) Identificação de possíveis casos de vazamento de dados (data leakage)



Principais Achados


A EDA revelou padrões críticos que orientaram todo o pipeline de modelagem:

- **Desbalanceamento acentuado** entre classes fraude e não fraude
- **Correlações suspeitas** entre algumas features e o target
- **Data leakage** — risco de o modelo aprender padrões irreais



Resultados muito altos na primeira análise acenderam um sinal de alerta para possível vazamento de dados.

Pré-processamento



Variáveis como `device_risk_score`, `ip_risk_score` e `country_ng` foram removidas por apresentarem correlação direta com o target — o que induziria o modelo a "trapacear" durante o treinamento.

Modelos Utilizados

Random Forest

Conjunto de árvores de decisão com votação por maioria. Robusto a outliers e com boa interpretabilidade das features mais relevantes.


XGBoost

Gradient boosting otimizado para alta performance. Constrói modelos sequenciais corrigindo os erros do anterior.

RandomizedSearchCV


Ajuste de hiperparâmetros via busca aleatória, explorando o espaço de parâmetros de forma eficiente e reduzindo overfitting.

Machine Learning Model. Training Phase



Resultados: Comparativo dos Modelos

Precisão (%) Recall (%) F1-Score (%)



Métricas referentes à **Classe 1 (fraude)**. O Random Forest foi selecionado como modelo final por apresentar maior recall — detectando mais fraudes com zero falsos positivos.



Modelo Final: Random Forest

98%

Recall (Fraude)

Das fraudes reais, 98% foram detectadas corretamente

0

Falsos Positivos

Nenhum cliente legítimo foi bloqueado indevidamente

2

Fraudes Perdidas

Apenas 2 casos de fraude não foram detectados

Impacto e Aprendizados

Principais Aprendizados

- **Resultados muito altos** nem sempre são confiáveis — podem indicar data leakage.
- Remover variáveis "viciadas" **melhora a generalização** real do modelo.
- O **equilíbrio entre precisão e recall** é mais valioso do que a acurácia isolada.

Impacto do Modelo

Menos Prejuízo

98% das fraudes detectadas antes de causarem dano financeiro

Melhor Experiência

Zero bloqueios indevidos — clientes legítimos não são impactados

Próximos Passos

1

Dados Reais

Testar o modelo em transações reais para validar a generalização além do dataset sintético

2

Validação Robusta

Aplicar cross-validation mais ampla e técnicas como k-fold estratificado para estimativas mais confiáveis

3

Produção

Avaliar desempenho em ambiente de produção com monitoramento contínuo de drift e re-treinamento periódico



Sugestões e contribuições são bem-vindas 😊